



**Tecnológico  
de Monterrey**

**Implementación de una técnica de aprendizaje máquina sin el uso de un  
framework**

Inteligencia artificial avanzada para la ciencia de datos (Gpo 601)

Alejandro Vázquez de la Cruz

02 de septiembre 2026

# Predicción de Churn

## Dataset

Se utilizó el dataset público Telco Customer Churn (7,043 clientes, 21 columnas). La variable objetivo es Churn con la siguiente distribución de clases:

| Clase       | Clientes | Proporción |
|-------------|----------|------------|
| No          | 5,174    | 73.5%      |
| Yes (churn) | 1,869    | 26.5%      |

El dataset está moderadamente desbalanceado, ya que más de la mitad de los datos estan en la clase de No churn.

Limpieza aplicada:

- customerID se descartó por ser solo un identificador, sin valor predictivo.
- TotalCharges venía como texto por 11 filas en blanco. Esas filas corresponden a clientes con tenure = 0 (recién dados de alta), así que se imputaron a 0 en vez de eliminarse.

División train/test: 80% entrenamiento (5,634 filas) / 20% prueba (1,409 filas), estratificada por Churn para conservar la misma proporción de clases en ambos conjuntos.

## Árbol de decisión

El algoritmo (decision\_tree.py) esta implementado con math y pandas, se utilizo el siguiente cálculo de entropía:

$$Entropy(S) = - \sum p_i \cdot \log_2(p_i)$$


$$Gain(S, split) = Entropy(S) - \sum (|S_v| / |S|) \cdot Entropy(S_v)$$

Hiperparámetros usados para controlar el overfitting:

- max\_depth = 5
- min\_samples\_split = 20


## Aplicación del Algoritmo

El nodo raíz elegido fue Contract == Month-to-month (ganancia = 0.134), muy por encima del siguiente mejor atributo (InternetService == Fiber optic, ganancia = 0.056). Esto quiere decir que los clientes sin permanencia contractual son los que más rotan. El árbol completo tiene profundidad 5 elegido arbitrariamente; por legibilidad se muestra limitado a 3 niveles en la siguiente imagen:



## Resultados sobre el conjunto de prueba

Matriz de confusión (1,409 clientes de prueba):



Métricas de evaluación:

| Métrica   | Valor |
|-----------|-------|
| Accuracy  | 79.8% |
| Precision | 63.3% |
| Recall    | 56.7% |
| F1-score  | 59.8% |

Dado que las clases están desbalanceadas (73.5% / 26.5%), el accuracy por sí solo puede ser engañoso, un modelo que siempre prediga "No" tendría 73.5% de accuracy sin ser útil. Por eso se reportan también precision y recall sobre la clase positiva (Churn = Yes):

- Recall (56.7%): de los clientes que realmente hacen churn, el modelo detecta poco más de la mitad.
- Precision (63.3%): de los clientes que el modelo marca como "van a hacer churn", 6 de cada 10 predicciones son correctas.
- F1-score (59.8%): balance entre ambas, útil como métrica única de comparación entre modelos.

## Comparación contra scikit-learn

Se entrenó un DecisionTreeClassifier(criterion='entropy', max\_depth=5, min\_samples\_split=20) con los mismos hiperparámetros, sobre el mismo split de datos (las variables categóricas se codificaron con LabelEncoder, ya que sklearn requiere entradas numéricas):

| Métrica   | Árbol manual | sklearn (entropy) |
|-----------|--------------|-------------------|
| Accuracy  | 79.8%        | 78.4%             |
| Precision | 63.3%        | 60.2%             |
| Recall    | 56.7%        | 55.3%             |
| F1-score  | 59.8%        | 57.7%             |

El desempeño es prácticamente equivalente entre ambas implementaciones, lo cual valida el algoritmo manual.

## Análisis y conclusión

El árbol de decisión implementado manualmente alcanza un desempeño (79.8% accuracy, F1 = 59.8%) prácticamente idéntico al de scikit-learn bajo los mismos hiperparámetros, lo que es la evidencia más directa de que la implementación del algoritmo, cálculo de entropía, ganancia de información y construcción recursiva del árbol, es correcta.

El resultado también es interpretable en términos del dataset, el atributo más informativo con una diferencia amplia es el tipo de contrato (Contract == Month-to-month, ganancia = 0.134, casi 2.4 veces la ganancia del siguiente mejor atributo), seguido por el tipo de servicio de internet y la antigüedad del cliente (tenure). Esto quiere decir que los clientes sin permanencia contractual y con poco tiempo en el servicio son los de mayor riesgo.

La limitación más importante del modelo es el recall (56.7%): de cada 10 clientes que efectivamente cancelan el servicio, el árbol solo detecta poco más de 5. Esto se explica en parte por el desbalance de clases (26.5% de churn) y en parte por las restricciones impuestas (max\_depth = 5, min\_samples\_split = 20), que limitan qué tan específicas pueden ser las reglas que aprende el árbol. Aumentar la profundidad probablemente subiría el recall en entrenamiento, pero a costa de generalizar peor sobre datos nuevos.